Senty

Балакший Андрей Сухочев Александр
Куратор:Юрий Курочкин

19 мая 2015

О проекте

Сентиментальная разметка коротких текстов с использованием "чистой" разметки обучающего множества.

Вдохновение

Прочитали статью исследователей из Стэнфордского университета о сентиментальной разметке твитов. Они производили "грязную" разметку твитов(разметка по смайликам) и обучались по ней.

http://cs.stanford.edu/people/alecmgo/papers/TwitterDistantSupervision09.pdf

Вдохновение

Прочитали статью исследователей из Стэнфордского университета о сентиментальной разметке твитов. Они производили "грязную" разметку твитов(разметка по смайликам) и обучались по ней.

http://cs.stanford.edu/people/alecmgo/papers/TwitterDistantSupervision09.pdf

Захотелось чего-то аналогичного, но с русским языком и с "чистой" разметкой (разметкой вручную).

Цель

Хотим по короткому тексту понимать настроение его автора.

Этапы выполнения

- Найти источник материалов для обучения, содержащий высказывания людей на различные темы.
- Разметить эти материалы вручную на положительные, отрицательные и нейтральные.
- Придумать различные признаки, которые помогут определять настроения авторов текстов (далее для упрощения будем называть эти признаки фичами).
- Реализовать машинное обучение с учётом этих признаков.

Получение материалов для обучения

Материалы для обучения спарсили с цитатника рунета bash.im. Для парсинга воспользовались питоновской библиотекой Beautiful Soup.

"Чистая"разметка обучающего множества

Для удобства "чистой" разметки текстов (далее башей) написали приложение под Android, чтобы размечать баши где угодно и когда угодно.

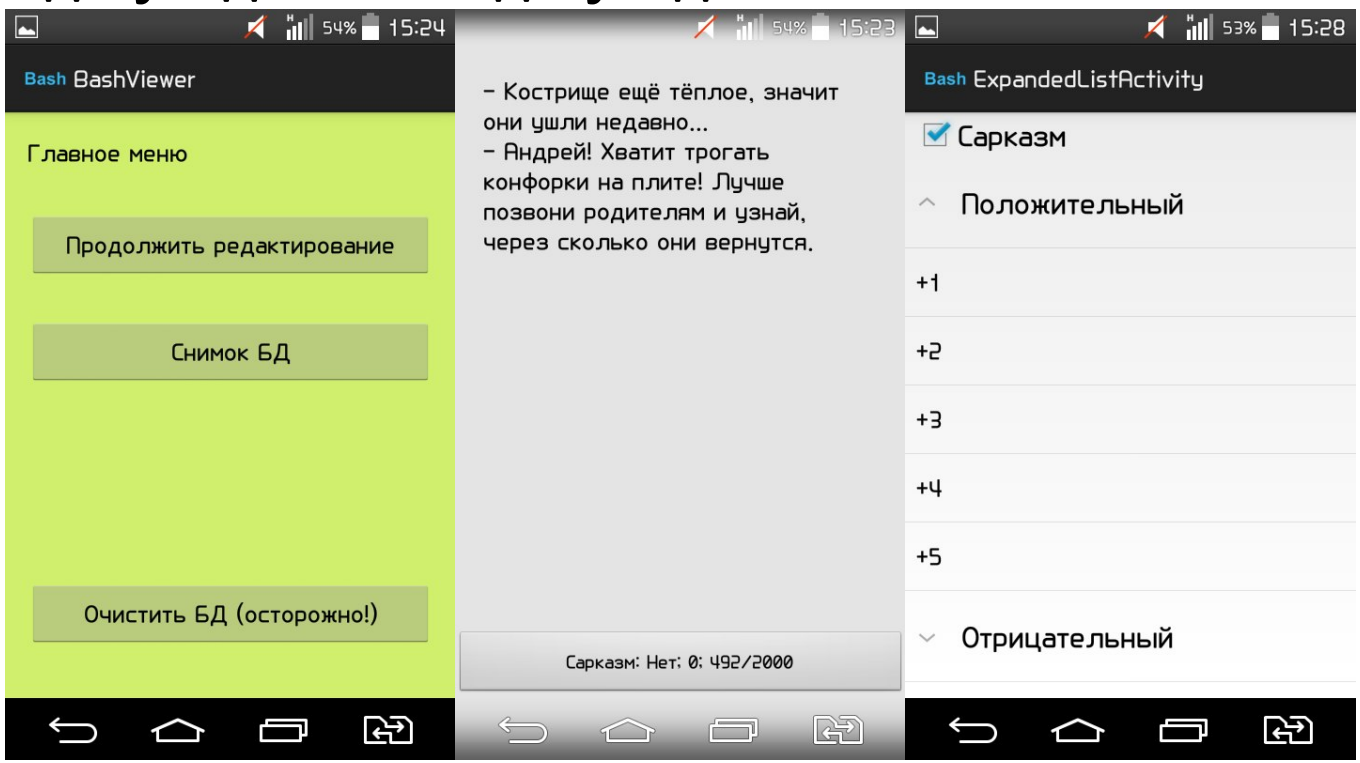

Фичи

Было создано множество фич, являющихся надстройками над стандартным экстрактором термов. В стандартном экстракторе мы просто убирали знаки препинания и нормализовывали слова с помощью питоновской библиотеки pymystem3.

Примеры работы некоторых фич

- **Исходный текст:**
  "УЖАААСНО не люблю вставать по понедельникам и идти на работу ((((,... и по вторникам тоже))"

Примеры работы некоторых фич

- **Исходный текст:**
  "УЖАААСНО не люблю вставать по понедельникам и идти на работу ((((,... и по вторникам тоже))"
- **Работа стандартного экстрактора с pymystem3:**
  "ужааасно не любить вставать по понедельник и идти на работа ((((и по вторник тоже))"

Примеры работы некоторых фич

- **Исходный текст:**
  "УЖАААСНО не люблю вставать по понедельникам и идти на работу ((((,... и по вторникам тоже))"
- **Работа стандартного экстрактора с pymystem3:**
  "ужааасно не любить вставать по понедельник и идти на работа ((((и по вторник тоже))"
- **Добавление фичи, убирающей предлоги, союзы и местоимения:**
  "ужааасно не любить вставать понедельник идти работа ((((вторник тоже))"

Примеры работы некоторых фич

- **Исходный текст:**
  "УЖАААСНО не люблю вставать по понедельникам и идти на работу ((((,... и по вторникам тоже))"
- **Работа стандартного экстрактора с pymystem3:**
  "ужааасно не любить вставать по понедельник и идти на работа ((((и по вторник тоже))"
- **Добавление фичи, убирающей предлоги, союзы и местоимения:**
  "ужааасно не любить вставать понедельник идти работа ((((вторник тоже))"
- **Добавление фичи, убирающей повторяющиеся буквы:**
  "ужасно не любить вставать понедельник идти работа ((((вторник тоже))"

Примеры работы некоторых фич

- **Исходный текст:**
  "УЖАААСНО не люблю вставать по понедельникам и идти на работу ((((,... и по вторникам тоже))"
- **Добавление фичи, склеивающей "не" со словом, которому эта частица принадлежит:**
  "ужасно нелюбить вставать понедельник идти работа ((((вторник тоже"

Примеры работы некоторых фич

- **Исходный текст:**
  "УЖАААСНО не люблю вставать по понедельникам и идти на работу ((((,... и по вторникам тоже))"
- **Добавление фичи, склеивающей "не" со словом, которому эта частица принадлежит:**
  "ужасно нелюбить вставать понедельник идти работа ((((вторник тоже"
- **Добавление фичи, выделяющей смайлики:**
  "ужасно нелюбить вставать понедельник идти работа плохосмайл вторник тоже хоросмайл"

Примеры работы некоторых фич

- **Исходный текст:**
  "УЖАААСНО не люблю вставать по понедельникам и идти на работу ((((,... и по вторникам тоже))"
- **Добавление фичи, склеивающей "не" со словом, которому эта частица принадлежит:**
  "ужасно нелюбить вставать понедельник идти работа ((((вторник тоже"
- **Добавление фичи, выделяющей смайлики:**
  "ужасно нелюбить вставать понедельник идти работа плохосмайл вторник тоже хоросмайл"
- **Также были созданы фичи, выделяющие n-граммы, убирающие иностранные слова и многие другие.**

Выбор классификаторов

- Naive Bayes
- SVM
- MaxEntropy

Для их реализации использовали питоновскую библиотеку scikit-learn.

Структура проекта

Для использования различных комбинаций фич с различными классификаторами была использована следующая структура.

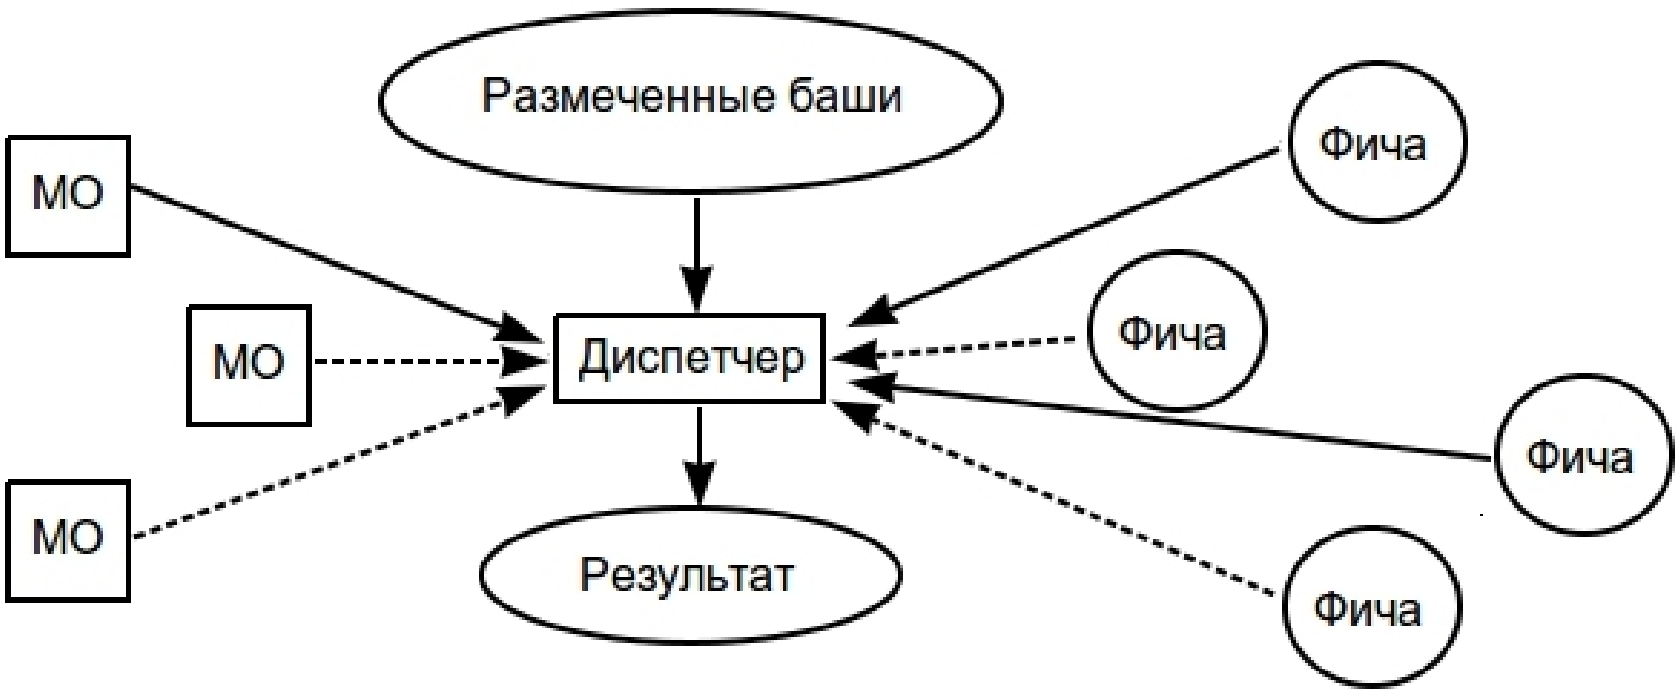

Результаты(Max Entropy)

Фичи и точность:

- **Стандартный экстрактор без фич - 70,58%**
- **+ убираем союзы - 70,85%**
- **+ биграммы с "не" - 70,94%**

Итого удалось повысить точность на 0,36%

Результаты(Naive Bayes)

Фичи и точность:

- **Стандартный экстрактор без фич - 65,83%**
- **+ убираем повторяющиеся буквы - 66,37%**
- **+ биграммы с "не" - 66,83%**
- **+ убираем иностранные слова - 67,17%**
- **+ выделяем смайлики - 67,26%**

Итого удалось повысить точность на 1,43%

Результаты(SVM)

Фичи и точность:

- **Стандартный экстрактор без фич - 70,31%**
- **+ убираем повторяющиеся буквы - 70,67%**
- **+ убираем союзы - 70,76%**
- **+ биграммы с "не" - 71,39%**

Итого удалось повысить точность на 1,08%

Проблемы

- Малый объём выборки(примерно каждый четвёртый баш является эмоционально окрашенным, много сарказма, "чистая" разметка - дело не быстрое). Всего 9811 различных термов было выделено стандартным экстрактором.
- Сильный "перекос" в сторону отрицательных башей в обучающей выборке: из 1115 башей, имеющих эмоциональную окраску, 732 являются отрицательными (65.65%).

Дальнейшие перспективы

- Двойная классификация: сначала классифицировать на нейтральное/с эмоциональной окраской, а потом уже эмоциональные на положительные/отрицательные.
- Прикрутить поиск по упоминаниям по базе башей для определения (с возможностью получения детальной информации с помощью какого-нибудь фильтра), сколько раз о предмете поиска отзывались положительно/отрицательно/нейтрально.
- Увеличение объёма материала для обучения.

Итоги практики

- Работа в команде
- Изучение Python(pymystem3, Scikit-learn, Beautiful Soup)
- Работа с GitHub
- Работа с LaTeX(собственно создание самой презентации)

LaTeX

Спасибо за внимание

https://github.com/cscenter/senty